

MerRec

Gợi ý sản phẩm từ dữ liệu hành vi

Phân tích dữ liệu · Xây dựng đặc trưng
Thực nghiệm mô hình Top-K

Nhóm thực hiện: [Tên nhóm] | GVHD: [Tên giảng viên]

174,87M

tương tác

30,05M

item

05/2023

dữ liệu quan sát

Nội dung trình bày

01

Introduction

Bối cảnh và mục tiêu

02

Problem Definition

Bài toán và thách thức

03

Dataset Description

Quy mô và cấu trúc

04

Data Preprocessing

Làm sạch và chia tập

05

EDA

Khám phá dữ liệu

06

Feature Engineering

Biểu diễn dữ liệu

07

Models

Các hướng mô hình

08

Model Training

Huấn luyện

09

Results

Kết quả và giao thức

11

Conclusion

Kết luận và hướng đi

10 Web Application / Demo được tách thành phụ lục, trang 39–40.

Bối cảnh và thực trạng thương mại điện tử

>25 tỷ USD

Quy mô TMĐT Việt Nam · 2024

+20%

Tăng trưởng so với năm 2023

- Nhu cầu ứng dụng: giúp người mua khám phá sản phẩm phù hợp trong catalog đa dạng.
- Bài toán nghiên cứu: khai thác dữ liệu hành vi và metadata cho gợi ý C2C.

Bối cảnh: Việt Nam. Dữ liệu thực nghiệm: MerRec từ Mercari — hai phạm vi khác nhau.

[Nguồn: Bộ Công Thương, báo cáo năm 2024 \(18/02/2025\); Li et al., MerRec \(2024\).](#)

Vấn đề thực tiễn: tìm sản phẩm nào giữa catalog lớn?

GÓC NHÌN NGƯỜI DÙNG

- Cần thu hẹp lựa chọn theo mối quan tâm.
- Từ khóa cần diễn đạt rõ nhu cầu.
- Danh sách phổ biến không tự phản ánh sở thích riêng.

BẢNG CHỨNG TỪ MERREC

30,05M

item trong lát dữ liệu

71,17%

item có dưới 5 tương tác

84,55%

sự kiện là lượt xem

Động lực: tận dụng nhiều tín hiệu để gợi ý một danh sách ngắn phù hợp hơn.

Lý do chọn đề tài

01 · Tính thực tiễn

Hỗ trợ khám phá sản phẩm từ nhu cầu và lịch sử người dùng.

02 · Tính học thuật

Nghiên cứu implicit feedback, long-tail, cold-start và chuỗi.

03 · Dữ liệu phù hợp

MerRec có timestamp, nhiều hành vi và metadata để thực nghiệm.

04 · Khả năng ứng dụng

Kết nối xử lý dữ liệu, mô hình và giao diện minh họa.

Giá trị kỳ vọng của đề tài; chưa phải bằng chứng tăng doanh thu hoặc hiệu quả online.

Mục tiêu, ý nghĩa và phạm vi nghiên cứu

Xây dựng và đánh giá gợi ý Top-K từ dữ liệu hành vi MerRec

CÔNG VIỆC

Xử lý dữ liệu và EDA.
Tạo đặc trưng.
Thực nghiệm mô hình.

Ý NGHĨA


Hiểu sparsity và cold-start.
Đọc đúng giao thức đánh giá.
Làm cơ sở tích hợp.

PHẠM VI

Dữ liệu tháng 05/2023.
Đánh giá offline.
Demo web tách riêng.

SASRec, DCN và LightGBM chưa hoàn tất; chưa có A/B test hoặc kiểm chứng kinh doanh.

Bài toán gợi ý và các thách thức



99,999843%

Độ thưa user-item

32,75%

Dòng TEST chứa cold item

Recall@K · HitRate@K · NDCG@K — đọc cùng coverage, tập user và candidate universe.

MerRec: quy mô và cấu trúc dữ liệu

174,87M

tương tác

2,77M

người dùng

30,05M

item_id duy nhất

Nhóm trường	Thông tin chính
Định danh	user_id · item_id · product_id
Hành vi / thời gian	event_id · stime · session_id · sequence_id
Metadata	name · price · category · brand · condition

312 file · ~21,57 GB · 913.718 product_id · Đồ án dùng lát tháng 05/2023.

[Nguồn: Li et al., MerRec \(2024\) và bảng tổng hợp local. Dataset gốc 6 tháng; đồ án dùng 1 tháng.](#)

Sáu loại hành vi

Tên sự kiện gốc	Tên chuẩn	Ý nghĩa
item_view	view	Xem sản phẩm
item_like	like	Thích sản phẩm
item_add_to_cart_tap	cart	Thêm vào giỏ
offer_make	offer	Đưa ra đề nghị
buy_start	buy_start	Bắt đầu mua
buy_comp	buy_comp	Hoàn tất mua

Pipeline tiền xử lý

BƯỚC 01

Parquet → VIEW

Đọc bằng DuckDB

BƯỚC 02

Chuẩn hóa

ID · thời gian · metadata

BƯỚC 03

Làm sạch

Lọc lỗi và khử trùng

BƯỚC 04

Temporal split

TRAIN → VAL → TEST

BƯỚC 05

Đặc trưng

ID maps · CF pairs · catalog

BƯỚC 06

Đầu ra

Snapshots · cold-start cohorts

Không nạp toàn bộ raw vào Pandas; xử lý theo VIEW, batch và file Parquet.

Làm sạch và khử trùng

174.872.167

Dòng trước xử lý



174.725.659

Dòng sau làm sạch


KHÓA KHỬ TRÙNG

user · item · event · timestamp · session · sequence

Tổng giảm 146.508 dòng; giữ một sự kiện trên mỗi khóa sau bước lọc hợp lệ.

Chuẩn hóa kiểu ID, trim chuỗi và parse timestamp theo đúng kiểu dữ liệu nguồn.


Xử lý metadata thiếu



- Color thiếu 95,61%; size_name thiếu 62,74%.
- Brand_name thiếu 19,20%; các trường tùy chọn không đồng nghĩa sự kiện vô dụng.
- Danh mục dùng cấp cha; brand/condition/shipper dùng __UNK__.
- Color không xuất vào interactions train/val/test.

Tỷ lệ missing theo dòng tương tác; giữ NULL của size ở bước chuẩn hóa.


Chia TRAIN / VAL / TEST theo thời gian



Tập	Thời gian UTC	Số tương tác
TRAIN	01–25/05	145.998.253
VAL	26–28/05	16.885.121
TEST	29/05–31/05 00:00	11.842.285

Integrity đã lưu: TRAIN kết thúc trước VAL; VAL kết thúc trước TEST.


ID mapping và cold-start



- Mapping chỉ xây từ TRAIN.
- 2.581.378 user và 27.328.461 item.
- TEST cold-item: 32,75% dòng.
- Tách warm, cold-user, cold-item và cold-both.


Cold-user và cold-item có phần giao nhau; không cộng ba cột thành tổng.

EDA: mất cân bằng hành vi



Tỷ lệ đếm hành vi, không phải conversion rate. Cart và offer đã dùng mapping đúng.



EDA: người dùng có phân bố dài đuôi



- Mean 63,23; median chỉ 12 tương tác/user.
- P95 = 275; P99 = 791.
- 13,31% user có đúng một tương tác.
- 31,36% user có dưới 5 tương tác.

Histogram trên mẫu 100.000 user; các số thống kê từ toàn bộ user.

EDA: long-tail của sản phẩm

**2**

Trung vị tương tác/item



71,17%

Item có dưới 5 tương tác

85,59%

Item có dưới 10 tương tác

EDA: các phiên tương tác thường ngắn



34,83M

Session theo user + session_id


2

Trung vị tương tác/session

37 giây


Trung vị thời lượng

EDA: thời gian và biên dữ liệu

**31/05: 88**

Ngày cuối không đầy đủ; không diễn giải là nhu cầu thị trường giảm.


EDA: mức độ quan tâm theo danh mục



- Women: 59,15 triệu tương tác, khoảng 33,83%.
- Toys & Collectibles: 32,90 triệu.
- Men: 15,67 triệu.
- Category phân cấp hỗ trợ biểu diễn nội dung và retrieval.

Trục số liệu là tương tác, không phải số item hoặc số người mua.

EDA: phân bố giá lệch phải



- Mean 62,69; median 25.
- P95 = 225; P99 = 636.
- Giá quan sát từ 1 đến 5.000.
- Two-Tower dùng $\log(1+\text{price})$, sau đó chuẩn hóa.


Theo đơn vị gốc của dataset; số liệu tổng hợp trên dòng tương tác.

Từ EDA đến quyết định mô hình hóa

Phát hiện	Quyết định / hướng xử lý
Sparsity $\approx 99,999843\%$	Thử implicit CF và biểu diễn metadata
25,53% tương tác là lặp thêm	Tổng hợp tín hiệu theo cặp user–item
Nhiều user/item ít lịch sử	Phân tích cold-start và phương án fallback
One-pass 5-core loại 22,33%	Chỉ là chẩn đoán, chưa áp dụng như bộ lọc cuối

Không loại bỏ hàng loạt long-tail trước khi đánh giá ảnh hưởng tới coverage.

Implicit feedback có trọng số



- $\text{implicit_score}(u,i)$ = tổng trọng số sự kiện.
- Giữ thêm số sự kiện theo loại.
- Giữ thời điểm tương tác cuối.
- 109.718.519 cặp user–item trong TRAIN.

Trọng số do dự án đặt; không phải tham số mô hình tự học.

Biểu diễn nội dung và metadata

CONTENT-BASED


- Name · category · brand · condition
- Hashing TF-IDF
- 262.144 chiều
- Unigram + bigram

TWO-TOWER

- 7 trường metadata + price
- Hashed embeddings
- Log-price chuẩn hóa
- Ghép vector → MLP

Hashing và xử lý theo batch giúp kiểm soát vocabulary và bộ nhớ.

Chuỗi item và hành vi cho GRU4Rec



32 chiều

Item embedding

16 chiều

Event embedding

100 bước

Giới hạn chuỗi

PAD = 0 · OOV = 1 · Hành vi là feature, nhãn là item tiếp theo.

Các nhóm mô hình và phạm vi thực nghiệm

NHÓM 01

Baseline / fallback

Popularity · Trending

Đã có snapshot

NHÓM 02

Nội dung / đồng xuất hiện

Content-Based · Co-visitation

Đã có kết quả TEST

NHÓM 03

Học biểu diễn

ALS · GRU4Rec · Two-Tower

Metric theo từng giao thức

Chưa hoàn tất: SASRec · DCN · LightGBM Ranker — không có số liệu trong bảng kết quả.

Popularity và Trending

$$\text{Trending} = \sum \text{weight} \times 0,5 ^ {(\text{tuổi sự kiện} / 3 \text{ ngày})}$$

100%

0 ngày

50%

3 ngày

25%

6 ngày


12,5%

9 ngày

Minh họa hệ số time-decay; không phải số liệu đo từ một mô hình.

Snapshot TRAIN dùng offline; snapshot toàn bộ processed phục vụ catalog/demo.


Content-Based: gợi ý từ hồ sơ nội dung



- Recency decay = 0,97 để tăng vai trò lịch sử gần.
- VAL: lịch sử TRAIN. TEST: lịch sử TRAIN + VAL.

Metadata và IDF dùng full catalog; cần ghi rõ giới hạn của temporal evaluation.


Co-visitation: quan hệ đồng xuất hiện



History	Decay	Reverse weight	Popularity penalty	Window
30 item	0,9	0,4	0,1	5


Chọn cấu hình trên VAL; refit TRAIN + VAL trước đánh giá TEST.

ALS: collaborative filtering cho implicit data




Ma trận tương tác

$\approx$



User factors

$\times$



Item factors

Factors	Regularization	Alpha	Iterations
32	0,15	40	12

Sơ đồ nguyên lý; cấu hình từ ALS artifact. Chọn model bằng POSITIVE NDCG@20.

GRU4Rec: học thứ tự và loại hành vi



- Item embedding trên CPU; GRU và dense được thiết kế chạy GPU.
- 64 negatives khi train; catalog lớn được truy cập theo batch.

METRIC HIỆN CÓ: SAMPLED VAL

Không gọi là full-catalog TEST.

Two-Tower: biểu diễn user và item



Symmetric InfoNCE + in-batch negatives · FAISS chứa 27.328.461 TRAIN item.


Thiết lập huấn luyện

Mô hình	Quy mô / batch	Vòng đã lưu	Chọn checkpoint
ALS	32 factors	12 iterations	POSITIVE NDCG@20
GRU4Rec	Batch 128; $\leq 1M$ windows/epoch	8 epoch	Sampled VAL Recall@20
Two-Tower	Batch 2.048	15 epoch	VAL POSITIVE NDCG@20


Đọc batch/row-group · Lưu checkpoint · Resume khi phiên chạy bị gián đoạn.

Theo dõi loss và chọn checkpoint

Đường huấn luyện từ history đã lưu




GRU4Rec: best checkpoint tại epoch 6



Two-Tower: best tại epoch 15

Hai hàm mục tiêu khác nhau: chỉ đọc xu hướng loss riêng từng mô hình.

Độc đúng giao thức đánh giá



- Recall: tỷ lệ target tìm thấy.
- HitRate: user có ít nhất một hit.
- NDCG: tính thêm vị trí của hit.
- Luôn ghi split, user, candidates và cách lọc.

Sampled VAL, candidate pool và full-index là các giao thức khác nhau.

Kết quả TEST hiện có — từng thực nghiệm riêng


Mô hình	Recall@20	NDCG@20	HitRate@20
Content-Based	1.2514%	0.004429	2.6042%
Co-visitation	1.2245%	0.006931	2.8298%
ALS	0.1122%	0.000347	0.2272%
Two-Tower	0.0729%	0.000263	0.1725%

TEST · TARGET POSITIVE

Khác tập user, candidate universe và coverage; chưa dùng để xếp hạng mô hình.

SASRec / DCN / LightGBM chưa có kết quả; GRU4Rec sampled VAL trình bày riêng.

Kết quả GRU4Rec và bài học đánh giá



15,69%

Recall@20 · epoch 6

1.810 user

1 target + 255 negatives

Sampled validation

Bước tiếp theo: thống nhất cohort/candidates và đo full-index trước khi chọn model.

Kết luận và hướng phát triển

ĐÃ THỰC HIỆN

- EDA và preprocessing 174,87M sự kiện.
- Nhiều hướng mô hình và artifact đã lưu.

ĐIỀU RÚT RA

- Long-tail và cold-item ảnh hưởng coverage.
- Giao thức đánh giá quyết định cách đọc metric.

BƯỚC TIẾP THEO

- Thống nhất benchmark; hoàn thiện SASRec/DCN/LightGBM.
- Tích hợp và đo chất lượng phục vụ.

Kết thúc nội dung nghiên cứu · Demo nằm riêng trong hai trang tiếp theo.

Demo MerRec — trình bày riêng

PHỤ LỤC DEMO · 30–60 GIÂY

CHÈN ẢNH TRANG CHỦ MERREC

Khung ảnh để thay bằng screenshot thực tế

- Khám phá sản phẩm
- Mở trang chi tiết
- Xem khu vực gợi ý

Ảnh demo và thảo luận

ẢNH CHI TIẾT SẢN PHẨM

ẢNH DEMO TÙY CHỌN

Cảm ơn thầy cô và các bạn

Câu hỏi & thảo luận